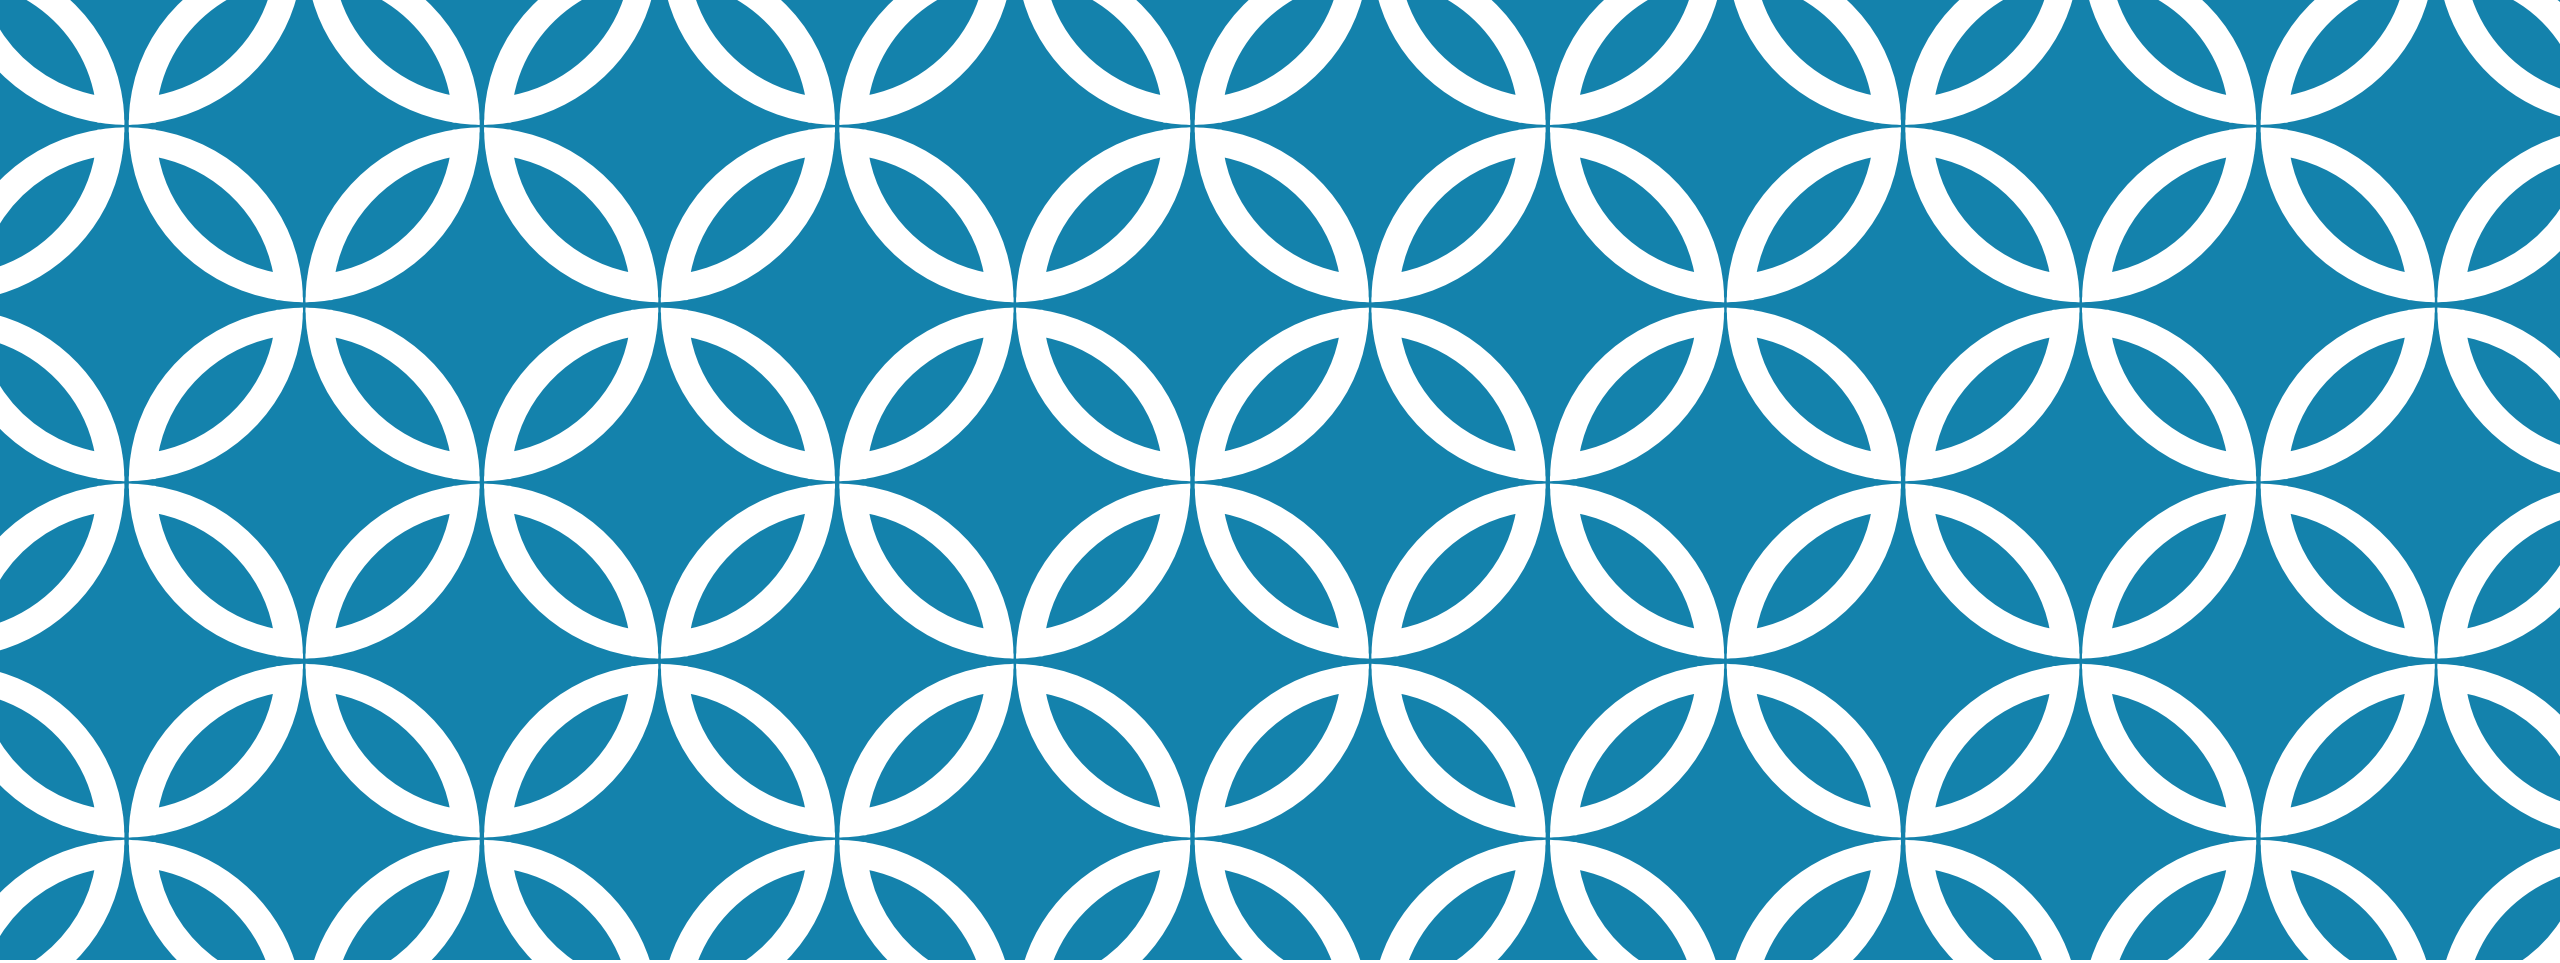


INTRODUCTION TO DATA ANALYTICS (數據分析導論)

Final Exam
Deadline: 2025-12-22 **5pm**

EXAM RULES & SUBMISSION

Rules:

- Discuss **within your group** only; **NO** communication across different groups.
- **Do not copy** from other groups.
- Violating the rules will lead to a penalty of **zero** points.
- 注意： deadline 是 今天 5PM

Q&A: 你可以在 Teams channel發問

Submission:

- Put the code and your answers (or insights) in ipynb files
- Compress your ipynb files and the data files in a .zip file like "2025_IDA_Final_Group_X.zip" (注意 X is your group id, 務必修改)
- Send e-mail to **imcjluh@g.yzu.edu.tw** via **your YZU mail**
  - **Subject (主旨): 2025**_IDA Final Group X files, (注意 X is your group id, 務必修改)
  - **CC （副本):** your team members
  - **Content (內容):** 你的組員學號
  - **Attachment(附件)**： 2025_IDA_Final_Group_X.zip

Q1: CONDUCT RFM ANALYSIS ON THE GIVEN DATA SET （70%）

1. Dataset: *data/Q1_data.xlsx*
2. Data preprocessing:
    1) Remove rows with null Member ID and OrderTotal
    2) Fill negative OrderTotal values with 0
    3) Exclude outliers
    4) Use Average Order Value (average amount of money a customer spends per order) as Monetary
    5) Ensure the Monetary values > 0
3. Find the best-fitted K for K-means clustering
4. Apply the K to cluster the preprocessed data
5. Conduct scale-based segmentation to the preprocessed RFM data
    1. You may use any point scales you prefer
    2. Re-group all possible segments into K segments

QUESTION – Q1

Notes:

1. Give a proper label to each cluster after K-means clustering. (e.g., 1: New; 2: Lost; 3: Best; 4: At Risk ….)
2. Give a similar label to each segment in scale-based segmentation

Question:

Compare K-means clusters with the K scale-based segments, which one is better for the data set? Justify your answer with Heat Map or Snake plots

Grading:

1) Kmeans Clustering with proper K (30%) （參考範例1）
2) K scale-based segments （20%） （參考範例2）
3) Comparisons with heatmap or snake plots（20%） （參考範例3）

儲存: *group_x_Q1.ipynb （x是你們的組別，記得要修改)*

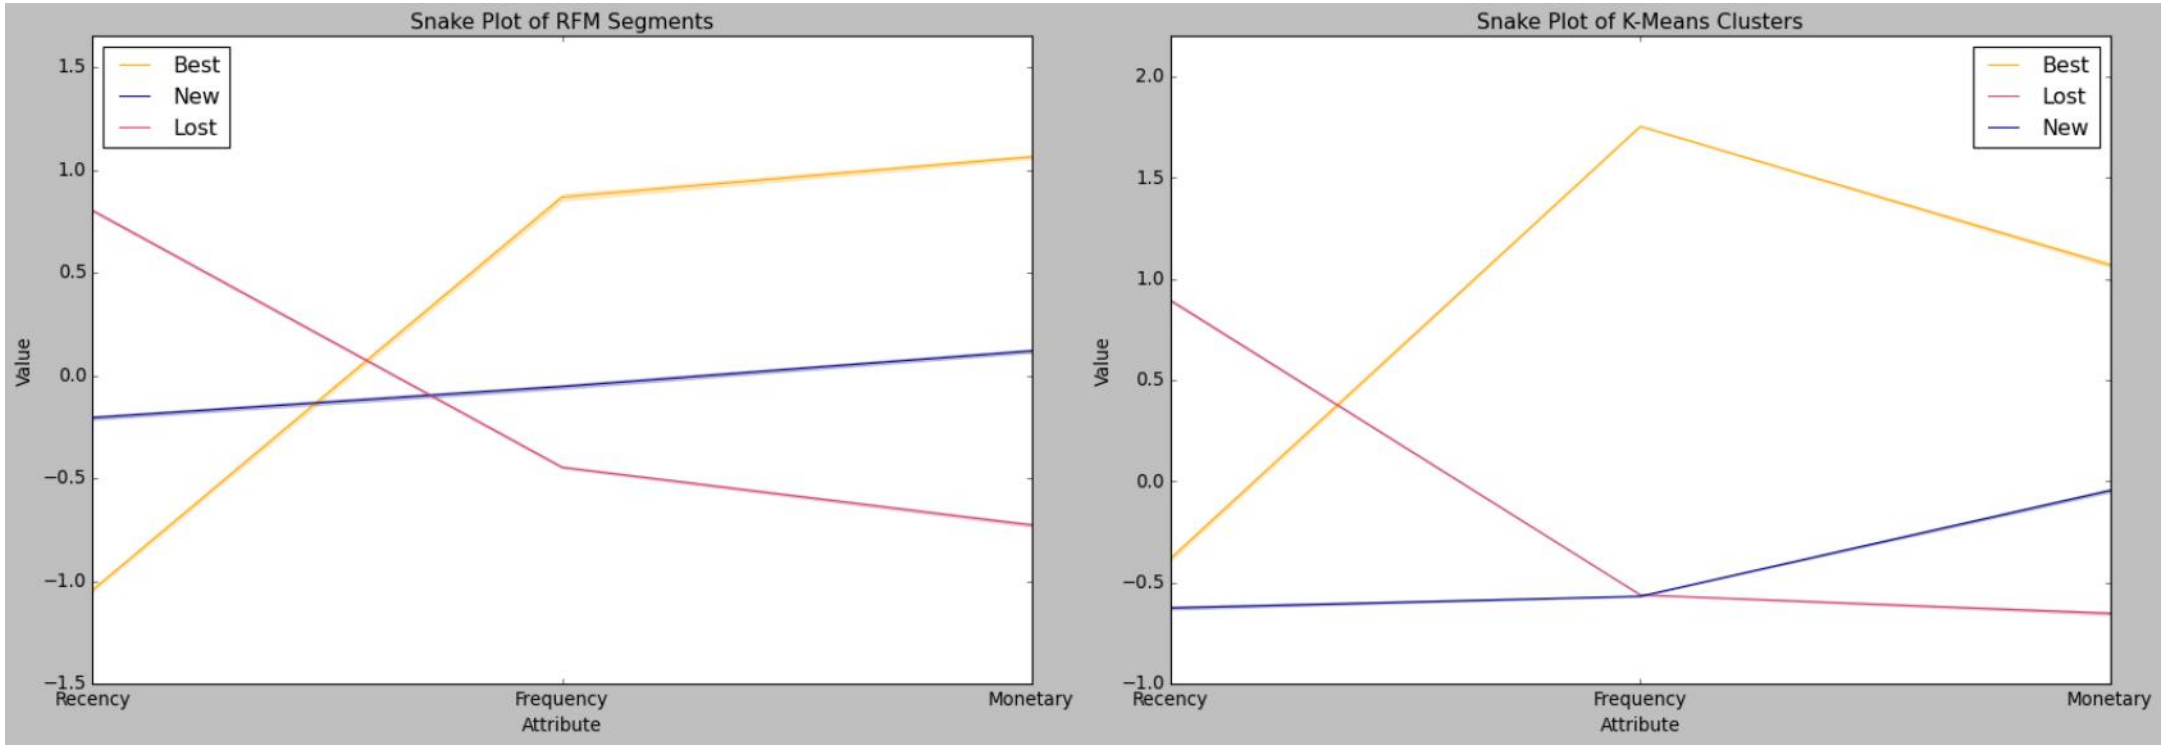
輸出範例 1 （示意圖，非真實數據）

Cluster	Recency	Frequency	Monetary	R	F	M	RFM_Combine	RFM_Score	RFM_Segment	%
0	22319	22319	22319	22319	22319	22319	22319	22319	22319	24.35%
1	34144	34144	34144	34144	34144	34144	34144	34144	34144	37.25%
2	35188	35188	35188	35188	35188	35188	35188	35188	35188	38.39%

輸出範例 2 （示意圖，非真實數據）

RFM_Segment	Recency	Frequency	Monetary	R	F	M	RFM_Combine	RFM_Score	Cluster	%
Lost	36022	36022	36022	36022	36022	36022	36022	36022	36022	39.3%
New	34846	34846	34846	34846	34846	34846	34846	34846	34846	38.02%
Best	20783	20783	20783	20783	20783	20783	20783	20783	20783	22.68%

輸出範例 3 （示意圖，非真實數據）



Q2: 統計分析 （30%）

1. **場景：** 某系希望評估三種不同管道入學學生的學業表現: 個人申請、考試分發以及繁星推薦。
2. **數據集:** data/Q2_students_with_scores.xlsx
3. **任務：**
   1) 進行**數據清理**，剔除無關的入學類型（例如：轉學考試）。
   2) 建立**虛無假設 (Null Hypothesis)** 與 **對立假設 (Alternative Hypothesis)**。
   3) 執行適當的**統計檢定** (例如ANOVA），判斷這三組學生的平均分數是否存在顯著差異。
   4) 若發現差異，請進行**事後檢定 (post-hoc test)**，明確指出哪些組別之間存在差異。
4. **評分:** （1）統計檢定結果 (15%) （2）事後檢定結果 (15%)
5. **儲存**: *group_x_Q2.ipynb（x 是你們的組別，記得要修改)*

輸出範例(非實際數據)

✓**Case 1: 有顯著差異**

統計檢定結果

F(2,27) = 5.12, p = 0.012 < 0.05 → 三組平均分數之間存在**顯著差異**。

事後檢定結果:

- A 與 B 沒有顯著差異。
- A 與 C、B 與 C 皆有顯著差異。
- **Group C 的分數顯著低於 A 與 B**

✓**Case 2: 沒有顯著差異**

F(2,27) = 0.38, p = 0.69 > 0.05 → 三組平均分數之間 **沒有顯著差異**。